## AthenaMP: Athena on steroids

### Sébastien Binet

Laboratoire de l'Accélérateur Linéaire

18-12-2008



## Athena: fiche technique framework basé sur GAUDI association de multiples composants élémentaires: ▶ Algorithm, AlgTool, Service.... un seul fil d'execution (single thread) reconstruction (14.5.0): rdotoesdnotrigger: \* ~ 1.6 Gb VMEM ★ ~ 10 s/evt (~ 24000 kSi2k) rdotoesd: ★ ~ 2.1 Gb VMEM ★ ~ 15 s/evt (~ 37000 kSi2k) esdt.oaod:



★ ~ 1.3 Gb VMEM
 ★ ~ 1 s/evt (~ 2500 kSi2k)

## hardware: tendance générale

- CPU ⇒ multicores
  - b chaque CPU peut comporter plusieurs (2 → ~ 1024) unités de calcul
- chaque core est moins rapide individuellement que les 'anciens' CPU
- mémoire plus restreinte (pour Athena)

Pour tirer parti des machines de la prochaine génération, il faut paralléliser Athena

### Problème


- solution usuelle: créer plusieurs threads d'execution
- MAIS: 90% du code n'est pas 'thread-safe'
- extrêmement dur de coder 'multi-threaded'
  - ► (et vous pensiez qu'Athena/C++ était compliqué?)

## Idée originale - proof of concept (Scott Snyder)

- utiliser plusieurs processus
  - par défaut, pas d'interférences entre processus
  - chaque processus a sa plage d'adresses mémoires
- pas de problème au niveau code client
  - pas de races, deadlocks,...
  - généralement, pas de modifications à apporter
- impact limité à certains composants 'core'
  - ▶ I/O (THistSvc, AthenaPoolCnvSvc, ...)

### recette AthenaMP (multiple-processes):

- créer une instance d'Athena
- ▶ procédure normale jusqu'à ::initialize
- processus parent fork n sous-processus
  - Linux partage efficacement la mémoire qui peut être partagée entre les différents processus
  - ★ pas d'explosion d'utilisation de la mémoire
  - swapping limité
- chaque sous-processus analyse m événements,
- ▶ puis appel de ::finalize
- processus parent collecte fichiers d'output + merge



## Implémentation (S. Binet)

- création d'un nouveau event loop manager: MpEventLoopMgr
  - encapsulation des détails MP
  - activation/désactivation via joboptions
- utilisation d'un module python (multiprocessing, dans la librairie standard de py-2.6) pour la gestion des sous-processus
  - pool de sous-processus (= ncores)
  - gestion des fichiers d'entrée et de sortie
- création d'un script pour merger les fichiers POOL et ROOT
  - ▶ de loin la partie la plus délicate (POOL, ElementLinks, ...)


### **Status**

- alpha code
- testé avec rdotoesdnotrigger et esdtoaod
- tourne OK mais tests plus approfondis nécessaires
  - ► développement des outils de validation en cours (PyDumper)

# Résultats préliminaires

## cpu - RecExCommon/esdtoaod

4procs 242.85s user 8.71s system 249% cpu 1:40.99 total 3procs 213.67s user 7.30s system 191% cpu 1:55.12 total 2procs 181.67s user 6.13s system 149% cpu 2:05.77 total 1procs 162.52s user 5.22s system 093% cpu 2:59.18 total 0procs 160.25s user 4.28s system 094% cpu 2:53.45 total



# Résultats préliminaires - II


## memory - RecExCommon/esdtoaod

```
process: \sim 700MB VMem and \sim 420MB RSS
```

(before) evt 0: private: 004 MB | shared: 310 MB (before) evt 1: private: 235 MB | shared: 265 MB

. . .

(before) evt50: private: 250 MB | shared: 263 MB



- développement d'un prompt interactif et MP
  - ▶ à la PROOF
  - réduction latence de l'analyse 'laptop'
- déploiement sur la grille
  - simples utilisateurs
  - production ?
  - problèmes d'interoperabilité avec les batch systems

#### Plus de tests:

- backnavigation (AOD → ESD → RDO)
- physics plots
- random numbers reproduceability
- reproduceability
- debugging tools
- ...

Backup...

### rational

- avoid client changes
- shove the MP-stuff inside Athena instead of putting it as a layer on top of it
- use the python module multiprocessing (backported from 2.6) for the process management
- write a new event loop manager as a usual Gaudi component to encapsulate the parallelism handling
- modify the I/O-related components appropriately

### \_worker\_bootstrap

- function called after fork
- change work dir
- reopen file descriptors
- tickle the IoComponentMgr

```
class IIoComponentMgr
  /** allow a @c IIoComponent to register itself with this
   * manager so appropriate actions can be taken when e.g.
   * a @c fork(2) has been issued (this is usually handled
   * by calling @c IIoComponent::io reinit on every registered
   * component)
   */
 virtual
  StatusCode io register (IIoComponent* iocomponent) = 0;
  /** @brief: reinitialize the I/O subsystem.
   * This effectively calls @c IIoComponent::io reinit on all
   * the registered @c IIoComponent.
 virtual
  StatusCode io reinitialize () = 0;
  /** @brief: finalize the I/O subsystem.
   * Hook to allow to e.g. give a chance to I/O subsystems to
   * merge output files.
   */
 virtual
  StatusCode io finalize () = 0;
```

```
class IIoComponent
{
   /** callback method to reinitialize the internal state of
   * the component for I/O purposes (e.g. upon @c fork(2))
   */
   virtual
   StatusCode io_reinit () = 0;
};
```

- implemented by THistSvc, AthenaPoolSvc, ...
- reopen input ROOT files
- open output ROOT files
  - created in the worker's own directory
  - take care of migrating all the objects of 'already opened for writting' ROOT files to the new ones

#### batch run

- inject a filter algorithm in front of alg-sequence
  - accept/reject events based on local process-id and current event number
- effectively implement a round-robin filter
- call the executeRun of the wrapped event loop manager

```
class MpEventLoopMgr (PyAthena.Svc):
    def finalize (self): ...
```

- tickle IIoComponentMgr::io\_finalize (when a forked process)
- master will run the merge of output files
  - usually trivial for ROOT files containing histos and ntuples
     trickier for ROOT/POOL files
    - \* take care of POOL links/references
      - \* take care of POOL links/references
      - actually just a few integers here and there to offset by the right amount
         needs some modifications in the AthenaPOOL layer to enable usage of the fast-merge mode (à la hadd)
      - \* right now: pedestrian/manual approach (slower)
  - ▶ I wish there were a general pool\_merge command!